能力现状与演进路线

标标 AI — 能力现状与演进路线

2026-03-24 | 回答：图片库、数据体量、自我迭代、自动抓取

一、图片库

📍 当前状态：❌ 未实现

当前系统只处理文本（PDF/Word/TXT 中的文字内容），**没有图片管理模块**。

🔧 需要建设什么？

技术标书中的图片需求非常明确——可以预分类：

图片分类	举例	管理方式
施工工艺图	钢筋绑扎节点图、模板支撑示意图	按工艺节点分类标签
施工流程图	施工工序流程、质量控制流程	按章节类型关联
平面布置图	施工现场临设布置	按项目类型模板化
进度计划图	甘特图、横道图	按工期动态生成
机械设备图	、塔吊、泵车照片	按设备型号索引
安全文明图	安全标识、围挡效果图	通用素材库
组织机构图	项目部组织架构图	按人员配置动态渲染

🏗️ 建设方案（建议 v0.4 迭代）

```
1. 新建 image_library 模块
   ├── 上传接口：支持 PNG/JPG/CAD 导出图
   ├── 标签系统：工艺类型 + 工程类型 + 章节关联
   ├── 搜索：按标签/关键词检索
   └── AI 自动插图：生成章节时自动匹配推荐图片

2. 数据模型
   ├── image_id (UUID)
   ├── filename / url
   ├── category (施工工艺/流程/布置/安全)
   ├── tags ["钢筋", "绑扎", "节点"]
   ├── applicable_sections ["施工方案", "质量保证"]
   └── tenant_id (租户隔离)

3. AI 集成
```

```
├── 章节生成时 → 检索匹配图片 → 插入占位符
└── Word 导出时 → 占位符替换为真实图片
```

📊 初期需要多少图片？

工程类型	建议图片量	覆盖范围
市政道路	80~120 张	路基、路面、排水、交安、绿化
房建工程	100~150 张	基坑、结构、装饰、机电、消防
水利工程	60~80 张	围堰、浇筑、防渗、闸门
通用素材	50~80 张	安全文明、环保、组织架构模板
合计初期	**~300 张**	覆盖核心工艺节点

二、初期测试需要的数据体量

📍 最小可用数据集（MVP Test）

类别	最低量	推荐量	说明
中标范文	3 份	10 份	同类型项目的完整技术标
招标文件	1 份	3 份	含评分标准的完整招标文件
行业规范	0 份	5 份	GB/T、JTG 等核心规范
企业资料	1 份	3 份	公司简介、业绩、资质
施工工艺	系统内置 248 个	—	工艺图谱已包含
知识切片总量	~500 条	~3000 条	系统自动切片

💡 测试阶段建议

```
第一周：投喂 3 份中标范文 + 1 份招标文件
        → 测试基本生成流程是否通畅

第二周：增加到 10 份范文 + 3 份规范
        → 对比生成质量提升幅度

第三周：加入企业资料 + 模拟多用户
        → 测试多租户隔离 + 个性化生成
```

三、系统自我迭代能力

📍 当前已实现：✅ 数据飞轮（被动进化）

```
用户反馈 → 飞轮机制 → 知识回灌
    ↓
✅ 采纳 → 原文标记为"优质语料"→ 提升类似内容生成权重
```

```
✏️ 修改 → 记录原文+修改版 → AI 学习修改偏好（diff_ratio）
❌ 拒绝 → 标记为"低质量"→ 降低类似输出概率
   ↓
flywheel_sunk 指标 → 已回灌到知识库的高质量语料数量
```

这是被动进化——依赖用户操作触发。

🔮 未来可建设：主动进化

能力	当前	目标
用户反馈学习	✅ 已有	持续优化
A/B 测试生成	❌	同一章节生成 2 版，用户选优
生成质量评分	❌	RAG 检索命中率自动统计
Prompt 自动调优	❌	基于反馈数据自动优化 Prompt
交叉学习	❌	租户 A 的优质语料（脱敏后）→ 全局知识

四、自动抓取招投标中心

📍 当前状态：❌ 未实现

🔧 可行性分析

维度	评估
技术可行性	✅ 高 — Python 爬虫生态成熟（Scrapy/Playwright）
法律风险	⚠️ 中 — 需确认各平台 robots.txt 和用户协议
数据价值	✅ 高 — 招标公告/中标公示/评分标准 是核心训练数据
实现复杂度	🟡 中 — 各地平台格式不统一，需要适配器模式

🏗️ 建设方案（建议 v0.5 迭代）

```
【可抓取的数据源】
├── 全国公共资源交易平台（统一接口）
├── 各省市公共资源交易中心
├── 中国招标投标公共服务平台
└── 行业垂直平台（建设工程招投标网等）

【可抓取的内容类型】
├── 招标公告 → 提取评分标准模板
├── 中标公示 → 学习中标价格/团队配置规律
├── 招标文件附件 → 扩充知识库
└── 行业动态/政策 → 更新规范引用

【架构设计】
```

```
                          ┌─ 调度器（APScheduler）
                          │    · 每日定时抓取
                          │    · 增量更新（防重复）
                          ↓
数据源适配器        →  内容清洗管道   →  知识库入库
（各平台接口）            · 去HTML          · 自动切片
                          · 提取正文        · 向量化
                          · 分类标签        · 租户:public
```

【伦理与合规红线】
├── ✅ 只抓取公开信息（招标公告、中标公示）
├── ✅ 遵守 robots.txt
├── ✅ 控制抓取频率（≤1次/秒，带 User-Agent）
├── ❌ 不抓取需要登录才能访问的内容
└── ❌ 不存储/传播涉及商业秘密的投标文件

五、演进路线图

```
v0.3（当前）                    v0.4（下一个）                v0.5（远期）
┌──────────────┐              ┌──────────────┐              ┌──────────────┐
│ ✅ 知识库文本 │              │ 🔧 图片库管理 │              │ 🔮 自动抓取招投标 │
│ ✅ AI 生成    │   →          │ 🔧 图片自动插入 │   →          │ 🔮 主动进化引擎  │
│ ✅ 反审标     │              │ 🔧 A/B 测试生成 │              │ 🔮 多源数据融合  │
│ ✅ 变体引擎   │              │ 🔧 生成质量评分 │              │ 🔮 Prompt 自调优 │
│ ✅ 数据飞轮   │              │ 🔧 OCR 图片识别 │              │ 🔮 跨租户知识沉淀 │
└──────────────┘              └──────────────┘              └──────────────┘
```

> [!IMPORTANT] **当前系统已具备"被动进化"能力**（数据飞轮）。图片库和主动爬取属于下一阶段建设，建议优先完成 v0.3 的测试验证后再启动。